

Primerjava izbranih jezikovnih modelov BERT za klasifikacijo čustev besedila

Tilen Koren
Fakulteta za elektrotehniko,
računalništvo in informatiko
Univerza v Mariboru
Koroška cesta 46, 2000
Maribor, Slovenija
tilen.koren
@student.um.si

Nejc Podvratnik
Fakulteta za elektrotehniko,
računalništvo in informatiko
Univerza v Mariboru
Koroška cesta 46, 2000
Maribor, Slovenija
nejc.podvratnik
@student.um.si

Viktorija Stevanoska
Fakulteta za elektrotehniko,
računalništvo in informatiko
Univerza v Mariboru
Koroška cesta 46, 2000
Maribor, Slovenija
viktorija.stevanoska
@student.um.si

POVZETEK

Predhodno naučeni jezikovni modeli Transformer so postali zelo priljubljeni in pomembni. Zaradi njihove prilagodljivosti in sposobnosti razumevanja in ustvarjanja človeku podobnega besedila so dragoceno orodje v številnih panogah in področjih. Ti modeli so prosto dostopni na spletu, kar omogoča njihovo široko uporabo, poleg tega pa se sčasoma še naprej razvijajo in izboljšujejo. BERT je izjemen primer vnaprej naučenega transformatorskega jezikovnega modela, ki je pomembno vplival na raziskave in aplikacije na področju obdelave naravnega jezika. V tem članku si bomo ogledali najpogostejše uporabljene jezikovne modele BERT, od katerih je vsak posebej prilagojen za določen namen. Opišemo njihove značilnosti in vsakega od njih natančno uglasimo nalogi klasifikacije čustev v angleškem besedilu, pri čemer vsak vnos razvrstimo v enega od sedmih različnih razredov. Poleg tega smo analizo razširili z natančnim uglaševanjem dodatnega modela BERT za klasificiranje čustev v slovenskem besedilu. Za ocenjevanje uspešnosti teh jezikovnih modelov uporabljamo več ocenjevalnih metrik, vključno s preciznostjo, natančnostjo, priklicem in F1-metrikjo. Na koncu jih primerjamo med seboj in tudi s vrednostmi, določenimi v predhodni raziskavi.

Ključne besede

BERT, klasifikacija sentimenta, transformer

1. UVOD

Jezikovni modeli **Transformer** [15] so vrsta arhitekture nevronske mreže, ki po učinkovitosti pri nalogah obdelave naravnega jezika presegajo povratne in konvolucijske arhitekture. Ključna inovacija modelov Transformer je mehanizem samopozornosti, ki modelu omogoča, da pri obdelavi zaporedja pretehta pomembnost različnih besed ali žetonov v zaporedju. Vendar bi bila majhna pomanjkljivost nekaterih teh modelov njihova enosmernost. Ti modeli pri obdelavi besede upoštevajo le predhodni kontekst, nimajo pa dostopa do naslednjega konteksta. Ta pristop je lahko računsko učinkovitejši in se lahko uporablja v scenarijih, kjer prihodnje informacije niso na voljo ali pomembne. Vendar bi bili v večini primerov dvosmerni modeli strogo gledano zmogljivejši od modela, ki obdeluje besede od leve proti desni ali od združitve modela od leve proti desni in modela od desne proti levi. Takšen model je leta 2018 razvil Google, znan kot dvosmerni kodirni predstavniki iz transformatorjev - **BERT**

(Bidirectional Encoder Representations from Transformers).

1.1 BERT in njegove različice

BERT [3] odpravlja prej omenjeno omejitev enosmernosti z uporabo maskirnega jezikovnega modela (**MLM** - masked language model). Pri izdelavi modela BERT sta bila uporabljena dva koraka: predhodno učenje in natančno uglaševanje. Med predhodnim učenjem se model uči na neoznačenih podatkih. V tem koraku zamaskirani model naključno zamaskira nekatere žetone na vhodu, cilj pa je napovedati izvirno besedo iz zamaskirane besede samo na podlagi njenega konteksta. Za razliko od učenja jezikovnih modelov od leve proti desni MLM združi levi in desni kontekst, kar omogoča ustrezen dvosmerni Transformer. Za natančno uglaševanje se model BERT najprej inicializira s predhodno naučenimi parametri, nato pa se vsi parametri natančno uglašijo z uporabo označenih podatkov.

V poglavju 5 primerjamo BERT z drugim modelom, ki je v vseh ocenjevanjih dosledno pokazal boljše rezultate - **XLNet** [16]. Gre za posplošen model, ki je kombinacija modela AR, ki poskuša oceniti verjetnostno porazdelitev korpusa, in modela Transformer. Čeprav je izkušnja pokazala, da je ta večji model boljši od modela BERT, je bilo izvedenih več izboljšav modela BERT, ki so dosegle primerljivo učinkovitost. Eden od teh pristopov je robustno optimiziran pristop za predhodno učenje BERT (**RoBERTa** - Robustly Optimized BERT Pretraining Approach) [5]. RoBERTa uvaja nekaj sprememb osnovnega modela BERT, vključno z daljšim učenjem modela in skupine paketov večjih velikosti, dinamičnim spreminjanjem vzorca maskiranja in izboljšanjem dela učenja z odstranitvijo nepotrebnih korakov.

Pri teh modelih velja splošno pravilo, da je večje boljše - modeli, ki se dlje časa učijo na večjih podatkovnih zbirkah, so vedno boljši od svojih manjših analogov. To predstavlja izziv glede časovne in prostorske učinkovitosti, zato so bila vložena naporja za optimizacijo delovanja BERT na napravah z omejenimi viri. Eden izmed takšnih modelov je **Albert** (A Lite BERT) [4]. V primerjavi z BERT-large (različica BERT-base, ki je naučena na večji podatkovni zbirki) ima Albert 18-krat manj parametrov in ga je mogoče naučiti približno 1,7-krat hitreje. Drug pomemben lahkni model je **Distilbert** [11], ki uporablja tehniko, imenovano destilacija znanja, pri kateri se manjši model - učenec - uči reprodukcije obnašanja večjega modela - učitelja. Raziskave so pokazale, da lahko ta za 40 % manjši model Transformer doseže

podobne rezultate pri različnih nalogah, hkrati pa je 60 % hitrejši pri sklepanju, zaradi česar je primeren za izvajanje na primer na mobilnih napravah.

1.2 Klasifikacija sentimenta

Spletna socialna omrežja so v današnjih okvirih ljudem omogočila svobodno izražanje mnenj kot še nikoli prej. Z razvojem tehnologije in področja obdelave naravnega jezika se je povečalo zanimanje za analizo in klasifikacijo čustev, ki izkorišča ta mnenja in povzema splošni učinek, ki ga imajo določene stvari ali dogodki na širšo javnost. Klasifikacija sentimenta je naloga, ki vključuje določanje čustev, izraženih v danem besedilu, kot so stavek, dokument ali objava v družabnih medijih. Naloga klasifikacije sentimenta lahko temelji na različnih tipologijah čustev, kot so emocije (veselje, strah, jeza, žalost), razpoloženje (veselo, mračno, razdražljivo, depresivno), medosebni odnosi (naklonjenost, ljubezen, sovraštvo, spoštovanje) itd. Uporabna je na primer podjetjem ali priporočilnim sistemom [8], pri ustvarjanju povzetkov izkušenj in mnenj ljudi, njena vloga pa je zelo raznolika - od spremljanja blagovnih znamk, upravljanja ugleda do trženjskih raziskav in razvoja izdelkov.

2. SORODNA DELA

V [1] so analizirali učinkovitost vnaprej naučenih modelov BERT, RoBERTa, DistilBERT in XLNet pri prepoznavanju čustev iz besedil. V članku je bil uporabljen nabor podatkov, ki je bil sestavljen na podlagi medkulturnih anketnih študij in vsebuje 7666 stavkov, razvrščenih v sedem različnih čustvenih razredov: veselje, jeza, žalost, sram, krivda, presenečenje in strah. Podatki so bili predprocesirani in razdeljeni v dve skupini: 80 % za učne namene in 20 % za testne namene. Izvedli so leksikalno analizo in so nato vzorci za učenje in testiranje bili posredovani modelom za natančno uglasjevanje. Dobljeni rezultati so bili nato analizirani na podlagi njihove točnosti, priklica in metrike F1. Eksperimenti so pokazali, da je RoBERTa s skupno oceno natančnosti 0,7431 presegel druge modele, medtem ko so XLNet, BERT in DistilBERT dosegli rezultate natančnosti 0,7299, 0,7009 in 0,6693.

V raziskavi [9], je bil model FinBERT preizkušen pri različnih nalogah na področju finančne obdelave naravnega jezika, vključno z analizo čustev, odkrivanjem vzročnosti, razumevanjem in pripisovanjem števil. Za učenje in testiranje je bilo uporabljenih šest različnih korpusov s teh podpodročij, opravljena pa je bila tudi primerjava med dvema osnovnima modeloma (BERT-base in Support Vector Machine) in dvema modeloma FinBERT. Prvi model FinBERT je bil inicializiran iz BERT-base in nato dodatno uglasjen na finančnih korpusih. Drugi model je bil učen na finančnih korpusih in uporabljal domensko-specifični finančni besednjak. Vsi modeli so bili ovrednoteni glede na njihovo makro F1 in mikro F1 metrike. Rezultati eksperimentov so pokazali, da so vsi predhodno naučeni modeli BERT v vseh finančnih podatkovnih zbirkah presegli model SVM, pri čemer je bilo razvidno, da je bil prvi model FinBERT običajno boljši od drugih modelov za obe metrike.

V [6] so se osredotočali na PPBERT in njegovo primerjavo z BERT-base. PPBERT je jezikovni model, ki za razliko od prejšnjih modelov, ki temeljijo na BERT, uvaža vmesni korak med korakom predhodnega učenja in uglasjevanja, kar pomaga bolje vključiti znanje o nalogah in domeni v pred-

Sentiment	Št. datotek
Jeza	1083
Gnus	1083
Strah	1087
Krivda	1074
Veselje	1097
Žalost	1084
Sramota	1076
Skupaj	7584

Tabela 1: Porazdelitev datotek v naboru podatkov na podlagi sentimenta

hodno naučen model. V članku [10] je prikazana primerjava med lastnim jezikovnim modelom BERT, prilagojenim za več domen, BERT-base in XLNet-base. Če povzamemo, razvoju novih in izboljšanih modelov je bilo posvečenega precej pozornosti, vendar nam je med našo raziskavo uspelo najti le en članek [1], ki primerja najpogostejše uporabljene modele BERT. To kaže na pomanjkanje pregledov na to temo in na morebitno neraziskano priložnost.

3. OPIS LASTNE IDEJE

Kot smo že omenili v prejšnjem poglavju, je naša ideja navdihnjena s člankom [1]. Poleg tega smo v primerjavo vključili lahki model Albert. Zanima nas tudi preverjanje uspešnosti klasifikacije sentimenta modelov BERT in DistilBERT pri uporabi za slovenska besedila. V ta namen smo uporabili večjezični model BERT, ki je predhodno naučen na velikem korpusu, sestavljenem iz podatkov iz različnih jezikov, vključno s slovenščino.

4. EKSPERIMENT

Eksperiment je potekal tako, da smo pridobili že predhodno naučeno različico modela in jo natančno uglasili za našo specifično panogo. Nato smo naložili učni korpus in ga razdelili na učno, testno in validacijsko množico. Model smo nato natančno uglasili in ocenili. Rezultati eksperimenta vključujejo metrike natančnosti, priklica, preciznosti, F1, čas učenja ter matriko klasifikacijskih napak.

Za izvajanje eksperimenta smo izbrali Google Colab, ki nam je omogočal sočasno delo z modeli in pospešilo naše delo s pomočjo strojnega pospeševanja. Tudi članek, na katerega se zgleđujemo, je uporabil Google Colab kot njihovo izvajalno okolje. Modeli so napisani v programskem jeziku Python, za predhodno trenirane modele pa smo uporabili modul transformers ter tensorflow in keras za delo z njimi.

4.1 Pridobivanje podatkov in predprocesiranje

Uporabili smo ISEAR podatkovno zbirko [13], ki ima 7584 primerov. Vsak primer izraža neko čustvo. Ta so veselje, žalost, jeza, gnus, sramota, strah in krivda. Ker podatkovna zbirka vsebuje veliko drugih podatkov o podani povedi smo te odstranili. Preoblikovali smo podatkovno zbirko na taki način, da je vsaki primer zapisan v svoji lastni tekstovni datoteki in bil shranjen v direktoriji z imenom čustva. Ker ne obstaja slovenska podatkovna zbirka, ki je ISEAR-u smo kompromisirali in prevedli ISEAR zbirko s pomočjo orodja Google Translate. Zbirko smo nato naložili v oblak in ga razdelili na učno, testno in validacijsko množico po razdelitvi 70-15-15.

Model	Čas učenja	Jeza			Gnus			Strah			Krivda			Vesetje			Žalost			Sramota		
		P	R	F1	P	R	F1	P	R	F1	P	R	F1	P	R	F1	P	R	F1	P	R	F1
XLNet	519s	0.65	0.64	0.65	0.77	0.52	0.62	0.81	0.71	0.76	0.64	0.69	0.66	0.81	0.91	0.85	0.56	0.80	0.66	0.61	0.51	0.56
Roberta	417s	0.60	0.64	0.62	0.66	0.73	0.69	0.68	0.77	0.72	0.67	0.74	0.70	0.89	0.85	0.87	0.75	0.72	0.73	0.67	0.47	0.55
DistilBERT SL	310s	0.48	0.58	0.53	0.57	0.54	0.55	0.79	0.62	0.69	0.57	0.52	0.54	0.56	0.85	0.67	0.72	0.60	0.66	0.52	0.41	0.46
DistilBERT EN	240s	0.63	0.46	0.53	0.65	0.54	0.59	0.72	0.85	0.78	0.55	0.65	0.60	0.87	0.84	0.85	0.69	0.74	0.71	0.51	0.53	0.52
Albert	358s	0.50	0.66	0.56	0.77	0.52	0.62	0.85	0.69	0.76	0.56	0.57	0.57	0.86	0.73	0.79	0.56	0.79	0.65	0.53	0.47	0.50
BERT Base SL	513s	0.46	0.58	0.51	0.74	0.48	0.58	0.60	0.83	0.70	0.54	0.62	0.57	0.73	0.76	0.74	0.64	0.62	0.63	0.61	0.33	0.43
BERT Base EN	419s	0.58	0.58	0.58	0.61	0.57	0.59	0.73	0.79	0.76	0.55	0.65	0.59	0.90	0.84	0.87	0.83	0.59	0.69	0.47	0.55	0.50

Tabela 2: Preciznost, priklic in F1-metrika za modele

4.2 Izvajanje eksperimenta


Pri izbiri hiperparametrov modela smo se tesno držali navodil iz članka [1]. Velikost skupine paketov smo nastavili na 16, hitrost učenja pa na 4×10^{-5} . Model je bil optimiziran z Adam optimizatorjem, pri čemer je bila izguba nastavljena na sparse categorical crossentropy. V nasprotju s člankom smo število epoh nastavili na 3, saj se je model v tretji epohi začel preprilagajati učnim podatkom. To smo zaznali s pomočjo validacijskih podatkov, ki jih članek ni uporabljal. Prav tako smo za razliko od članka nastavili seme modela na 42, kar je omogočilo natančnejšo primerjavo med modeli. Po končanem učenju smo pridobili rezultate vseh metrik in porabljeni čas učenja. Nato smo model ocenili na testni množici in na podlagi njene uspešnosti ustvarili matriko klasifikacijskih napak, ki jasno prikazuje, kako uspešen je model za posamezen razred čustev in katera čustva pogosto zamejuje med seboj.

5. REZULTATI IN DISKUSIJA


Rezultate smo predstavili v obliki matrik klasifikacijskih napak, kjer je razvidno, kako uspešno je bilo posamezno čustvo, ter katera čustva so se najpogosteje mešala med seboj. Opazujemo, da so vse vrste BERT-a sledile približno istemu trendu. Gnus, strah, veselje in žalost so bili precej uspešno prepoznani, medtem ko jeza, sramota in krivda nekoliko manj. Najpogosteje so BERT-i zamenjevali pri prepoznavanju sramote in krivde. Sklepamo, da je razlog za to, da sta si ti čustvi zelo podobni. Kar se tiče celovite natančnosti, sta slovenska BERT-a na dnu, kar smo tudi pričakovali. Sledita jima ALBERT in DistilBERT, ki žrtvujeta natančnost za boljše prostorsko in časovno učinkovitost. Presenečeni smo bili nad ugotovitvijo, da je BERT Base rahlo boljši od Roberta. Predvidevali smo, da bosta XLNet in Roberta na vrhu po natančnosti, vendar je BERT Base v našem eksperimentu pokazal rahlo večjo natančnost od Roberta.

Glede na druge metrike v tabeli 2 opazimo, da sta XLNet in Roberta prevladovala pri preciznosti, priklicu in F1 meri, vendar sta zaradi tega tudi počasnejša pri samem učenju kot tudi prepoznavanju. Najhitreje se je naučil angleški DistilBERT, saj je potreboval zgolj 240 sekund, kar je skoraj dvakrat hitreje kot večina drugih BERT-ov.


Na podlagi tega eksperimenta smo ugotovili, da je DistilBERT odličen kompromis med uspešnostjo in časom učenja ter porabo pomnilnika. Vsekakor je boljši od ALBERTA, ki je tudi zasnovan kot lažja različica BERT-a, in ga premaga v skoraj vseh kategorijah. Če nas zanima samo uspešnost modela, sta XLNet in Roberta dobri izbiri. Eksperiment je pokazal, da čeprav BERT Base ne dosega tako visoke preciznosti, priklica in F1-meri kot XLNet in Roberta, je še vedno primerljiv glede natančnosti in hitrosti učenja. Prav tako opazimo, da uporaba večjezičnega modela prinaša slabše re-




Slika 1: Matrika klasifikacijskih napak za model BERT-base, uglašen na angleškem korpusu.




Slika 2: Matrika klasifikacijskih napak za model BERT-base, uglašen na slovenskem korpusu.




Slika 3: Matrika klasifikacijskih napak za model RoBERTa, uglašen na angleškem korpusu.




Slika 5: Matrika klasifikacijskih napak za model Albert, uglašen na angleškem korpusu.



Slika 4: Matrika klasifikacijskih napak za model XLNet, uglašen na angleškem korpusu.



Slika 6: Matrika klasifikacijskih napak za model DistilBERT, uglašen na angleškem korpusu.



Slika 7: Matrika klasifikacijskih napak za model DistilBERT, uglasen na slovenskem korpusu.

zultate kot specializirani model za določen jezik. Možno je tudi, da je kakovost podatkovne zbirke poslabšala prevajanje. Možno je tudi, da je uporaba prevajalnika poslabšala kvaliteto podatkovne zbirke.

6. ZAKLJUČKI IN NADALJNJE DELO

Če povzamemo, predhodno naučeni jezikovni modeli Transformer, kot je BERT, so se zaradi svoje prilagodljivosti in učinkovitosti izkazali za neprecenljivo orodje ne le za klasifikacijo čustev, temveč tudi na drugih različnih področjih. Ta članek se osredotoča na najpogostejše uporabljene jezikovne modele BERT, za oceno njihove uspešnosti pa je bilo uporabljenih več metrik, vključno z natančnostjo, preciznostjo, priklicem in F1-metrikami. Izvedli smo eksperiment, ki je pokazal, da v primerjavi z drugimi jezikovnimi modeli XLNet dosledno dosega boljše rezultate pri vseh metrikah za klasifikacijo sentimenta. Z nadaljnjim razvojem teh modelov se bo njihov potencialni vpliv na različnih področjih le še povečeval. Z njihovim nenehnim izpopolnjevanjem in optimizacijo lahko izboljšamo njihovo učinkovitost in tako odpremo nove možnosti za obdelavo naravnega jezika.

7. REFERENCES

- [1] F. A. Acheampong, H. Nunoo-Mensah, and W. Chen. Comparative analyses of bert, roberta, distilbert, and xlnet for text-based emotion recognition. November 2020.
- [2] A. Chiorrini, C. Diamantini, A. Mircoli, and D. Potena. Emotion and sentiment analysis of tweets using bert. 3, 2021.
- [3] J. Devlin, M. Chang, K. Lee, and K. Toutanova. BERT: pre-training of deep bidirectional transformers for language understanding. *CoRR*, 2018.
- [4] Z. Lan, M. Chen, S. Goodman, K. Gimpel, P. Sharma, and R. Soricut. ALBERT: A lite BERT for self-supervised learning of language representations. *CoRR*, 2019.

- [5] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov. Roberta: A robustly optimized BERT pretraining approach. *CoRR*, 2019.
- [6] Z. Liu, W. Lin, Y. Shi, and J. Zhao. A robustly optimized bert pre-training approach with post-training. November 2019.
- [7] X. Ma, P. Xu, Z. Wang, R. Nallapati, and B. Xiang. Domain adaptation with bert-based domain classification and data selection. November 2019.
- [8] B. Pang and L. Lee. A sentimental education: Sentiment analysis using subjectivity summarization based on minimum cuts, 2004.
- [9] B. Peng, E. Chersoni, Y.-Y. Hsu, and C.-R. Huang. Is domain adaptation worth your investment? comparing bert and finbert on financial tasks. November 2021.
- [10] A. Rietzler, S. Stabinger, P. Opitz, and S. Engl. Adapt or get left behind: Domain adaptation through bert language model finetuning for aspect-target sentiment classification. August 2019.
- [11] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. *ArXiv*, 2019.
- [12] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. March 2020.
- [13] K. Scherer and H. Wallbott. Emotion and sentiment analysis of tweets using bert. 2017.
- [14] C. Sun, X. Qiu, Y. Xu, and X. Huang. How to fine-tune bert for text classification? 2019.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- [16] Z. Yang, Z. Dai, Y. Yang, J. G. Carbonell, R. Salakhutdinov, and Q. V. Le. Xlnet: Generalized autoregressive pretraining for language understanding. *CoRR*, 2019.